인공지능 콘텐츠 현지화 평가를 위한 문화 적합도 지표(Cultural Responsiveness Score, CRS) 구축*

권상희[1], 김원회[2], 정우일[3], 이준호[4]

I. 연구 목적과 문제의식

1.1 연구 배경

K-콘텐츠의 세계적 확산과 함께 웹툰은 대표적인 글로벌 디지털 서사 양식으로 자리 잡았으며, 동일한 작품이 여러 언어로 번역되어 동시에 유통되고 있다. 이에 따라 현지화는 단순한 사후 공정이 아니라 작품의 접근성·몰입도와 글로벌 성과를 좌우하는 핵심 생산 과정으로 변화하고 있다. 다국어 동시 연재가 확대되면서 인간 번역가와 검수자에게 의존하는 품질관리 방식은 비용과 처리 속도 측면에서 한계를 보이고 있다. 이를 보완하기 위해 AI 기반 번역·식자·리터칭 기술이 도입되고 있다. 식자(植字, lettering/typesetting)는 번역된 대사·내레이션·효과음을 말풍선과 이미지에 배치하고, 글꼴·크기·간격·줄바꿈·정렬 등을 시각적으로 조정하는 작업이다. AI 기반 현지화는 대규모 콘텐츠를 신속하게 처리할 수 있지만, 자동화된 산출물의 품질을 평가할 기준이 필요하다. 번역문이 원문의 의미를 충실하게 전달하더라도 타깃 문화의 언어 관습, 사회문화적 규범, 인물 관계, 유머 및 정서적 기대에 부합하지 않으면 독자에게 어색하게 수용될 수 있다. 따라서 AI 웹툰 현지화에는 언어적 정확성과 함께 문화적·화용적·시각적 수용성을 측정하는 평가체계가 요구된다.

1.2 기존 기계번역 평가지표의 한계

기존 기계번역 평가지표는 주로 원문·참조 번역과 평가 대상 번역문 사이의 어휘적·의미적 대응 관계를 측정한다. BLEU는 참조 번역과의 n-gram 중첩 정도를 산출하고(Papineni et al., 2002), METEOR는 어간·동의어와 단어 배열을 고려하여 어휘적 대응을 보완한다(Banerjee & Lavie, 2005). COMET은 사전학습 언어모델로 의미적 유사성과 번역 품질을 추정하며(Rei et al., 2020), MQM은 오역·누락·용어·문법·문체 등의 오류를 유형과 심각도에 따라 평가한다. 이러한 지표들은 번역의 정확성을 평가하는 데 유용하지만, 타깃 문화권 독자에게 얼마나 자연스럽고 적절하게 수용되는지를 직접 측정하는 데에는 한계가 있다. 의미

1) 성균관대학교/교수, skweon@skku.edu
2) 브레인벤처스/대표, whkim@brainventur.com
3) 성균관대학교/겸임교수, tacoma@skku.edu
4) 브레인벤처스/기술팀장, panic@brainventur.com

* 본 연구는 문화체육관광부 및 한국콘텐츠진흥원(KOCCA)의 「2026년 선도기업 연계 동반성장 지원사업」(과제번호: E2026-0083100001, 협력기관: 네이버클라우드), 과학기술정보통신부 및 정보통신산업진흥원(NIPA)의 「2026년 SaaS 개발·사업화 지원사업」(과제번호: PJT-26-040471), 고양시 및 고양산업진흥원(GIPA)의 「2026년 고양형 민간투자연계 기술창업 지원사업(고양TIPS)」의 지원을 받아 수행되었다.

적으로 충실한 번역이라도 효과음이 목표언어의 표현 관습과 다르거나 ‘수능’, ‘족발’, ‘꼰대’와 같은 문화특정항목이 그대로 직역되면 사회문화적 함의가 충분히 전달되지 않을 수 있다. 존대와 반말, 호칭과 친족어 등은 등장인물의 위계·친밀도·정서적 태도를 나타내므로, 이를 목표언어의 관습에 맞게 조정하지 못하면 인물 관계나 성격이 달라질 수 있다. 유머·언어유희·밈도 직역하면 본래의 기능이 소실되기 쉬우며, 경우에 따라 목표문화에서 유사한 기능을 수행하는 표현으로 치환하는 자국화(domestication)가 독자의 이해와 몰입을 높일 수 있다. 따라서 웹툰 현지화 품질을 정확성만으로 평가하기는 어렵다. 기존 지표가 원문의 정확한 전달 여부를 평가한다면, 문화 적합성 평가는 원문의 의미와 서사적 기능을 유지하면서도 번역 결과가 타깃 문화에서 자연스럽고 적절하게 수용되는지를 별도의 차원에서 평가해야 한다.

1.3 이론적 출발점과 문화 적합성의 정의

본 연구의 이론적 출발점은 문화 할인(cultural discount)이다. Hoskins와 Mirus(1988)는 미디어 상품에 원산지 문화의 가치관·행동양식·유머·상징 등이 배태되어 있어, 이러한 문화적 배경을 공유하지 않는 해외 수용자에게는 콘텐츠의 가치와 매력이 감소할 수 있다고 보았다. 이러한 관점에서 현지화는 언어 변환을 넘어 콘텐츠가 다른 문화권으로 이동하면서 발생하는 의미·정서 및 수용 가치의 손실을 조절하는 과정이다. 문화 할인은 주로 영화와 방송을 중심으로 논의되었지만, 언어적·시각적 요소가 결합된 웹툰에도 적용될 수 있다. 웹툰은 대사·내레이션, 의성어·효과음, 문화특정항목(CSI), 인물 관계와 말투, 표정·동작·배경 및 식자가 결합된 멀티모달 텍스트이다. 따라서 동일한 대사도 표정과 동작, 말풍선 형태, 글자의 크기와 배치에 따라 의미와 정서적 강도가 달라지며, 부적절한 행갈이·글꼴·배치는 독자의 몰입을 저해할 수 있다. 또한 본 연구는 원천문화와 타깃문화 간 차이를 평가조건에 반영하기 위해 홉스테드의 국가문화 차원을 바탕으로 문화 이퀄라이저(Cultural Equalizer, CEQ)를 구성한다. CEQ는 국가문화 차이를 번역 품질점수로 직접 가산·차감하는 지표가 아니라, 타깃 문화에서 중점적으로 확인할 평가문항과 판단 민감도, 근거 요구 수준 및 제한적 상대 가중치를 설정하는 조건변수로 활용한다.

이에 본 연구는 문화 적합성을 원작의 핵심 의미와 서사적 기능, 등장인물의 정체성을 유지하면서 현지화 결과물이 타깃 문화의 언어 관습, 사회문화적 규범, 정서적 기대 및 시각적 표현 관습에 적절하게 대응하는 정도로 정의한다. 문화 적합성은 원문의 의미를 임의로 변경하거나 목표문화의 고정관념에 맞추는 것이 아니라, 번역 정확성만으로 설명하기 어려운 문화적·화용적·시각적 수용성을 보완적으로 평가하는 개념이다. 따라서 원문의 핵심 의미와 서사 기능이 훼손된 번역은 목표문화에서 자연스럽더라도 높은 품질의 현지화로 평가할 수 없다.

1.4 연구 목적과 연구문제

본 연구는 AI 기반 웹툰 현지화의 문화 적합성을 정량적으로 평가하는 문화 적합도 지표(Cultural Responsiveness Score, CRS)를 설계하고, 그 타당도·신뢰도와 실무적 활용 가능성을 검증하는 데 목적이 있다. CRS는 기존 기계번역 지표를 대체하기보다, 기존 지표가 충분히 포착하지 못하는 문화적·화용적·시각적 품질을 진단하는 보완적 평가모형이다.

CRS는 의성어·효과음, 문화특정항목(CSI), 인물 관계와 말투, 유머·밈, 이미지-텍스트 정합성의 다섯 가지 긍정 차원과 문화적 위험 및 식자·배치·가독성 위험의 두 가지 감점 항목으로 구성된다. 이를 통해 총점뿐 아니라 문제의 발생 차원과 위치, 심각도, 판단 근거 및 수정 권고를 함께 제시한다.

자동 평가에는 LLM-as-a-Judge(Zheng et al., 2023)와 멀티모달 모델을 활용한다. 평가에 앞서 CEQ를 통해 타깃 국가의 문화적 차이에 따른 평가조건을 설정하고, 자동 산출된 CRS는 타깃 문화권 원어민 평가와 비교하여 수렴 타당도와 신뢰도를 검증하고, 감점 체계가 변별력과 안전성 향상에 기여하는지도 확인한다. 이에 따라 다음의 연구문제를 설정한다.

RQ1. AI 기반 웹툰 현지화의 문화 적합성은 어떠한 하위 차원으로 구성되며, 각 차원은 어떻게 조작화하고 정량화할 수 있는가?

RQ2. LLM-as-a-Judge와 멀티모달 모델로 산출한 CRS는 타깃 문화권 원어민의 문화적 자연스러움 및 수용성 평가와 어느 정도 일치하는가?

RQ3. 문화적 위험과 식자·배치·가독성 위험의 감점 체계는 CRS의 변별력·안전성 및 문제 진단 능력에 어떠한 영향을 미치는가?

CRS는 현지화 결과물의 문화적 품질을 비교하고 품질 저하의 원인을 진단하여 인간 검수가 필요한 장면을 선별하는 데 활용된다. 궁극적으로는 평가엔진·검수 대시보드·인간 평가 데이터셋에 공통으로 적용되는 명세를 제공하여 웹툰 현지화의 자동화와 품질관리를 연결하고자 한다.

II. 연구 내용과 방법

CRS는 원문·번역문 텍스트, 원문·현지화 패널의 이미지 쌍, 타깃 독자 프로필로 구성된 4-튜플을 입력으로 웹툰 현지화의 문화 적합성을 평가한다. 홉스테드의 국가문화 차원(Hofstede, 2011)은 문화 이퀄라이저(CEQ)로 변환하여 원천국과 타깃국 간 문화 차이를 평가조건으로 설정하는 데 활용한다. CEQ 자체를 번역 품질점수로 직접 가산·차감하지 않으며, 국가별 평가문항의 우선순위·판단 민감도·근거 요구 수준과 CRS 차원의 제한적 상대 가중치를 조정한다. LLM-as-a-Judge 파이프라인은 후보 식별,

조건부 채점, 멀티모달 정합성 검증과 위험 탐지를 수행하고 그 결과와 근거를 함께 저장한다.

CRS는 의성어·효과음, 문화특정항목(CSI), 인물 관계와 말투, 유머·밈, 이미지-텍스트 정합성의 다섯 긍정 차원을 평가하고, CEQ로 설정된 국가문화 조건을 평가 과정에 반영한다. 이후 각 차원의 점수를 가중합(加重合)하고 문화적 위험과 식자·배치·가독성 위험의 감점값을 차감하여 최종 CRS를 0-100점으로 산출한다. 문화적 위험은 종교·정치·인종·젠더·혐오·금기와 함께 현지 법규 및 플랫폼 정책을 고려하여 판단한다. 인간 평가는 총점에 합산하지 않고 자동 평가의 타당도와 신뢰도를 검증하는 외부 준거로 활용한다. 잠정 운영 기준은 90점 이상 자동 연재 후보, 70점 이상 90점 미만 전문가 검수·수정, 70점 미만 재현지화 권고이다.



[그림 1] CRS 연구 전체 개념도

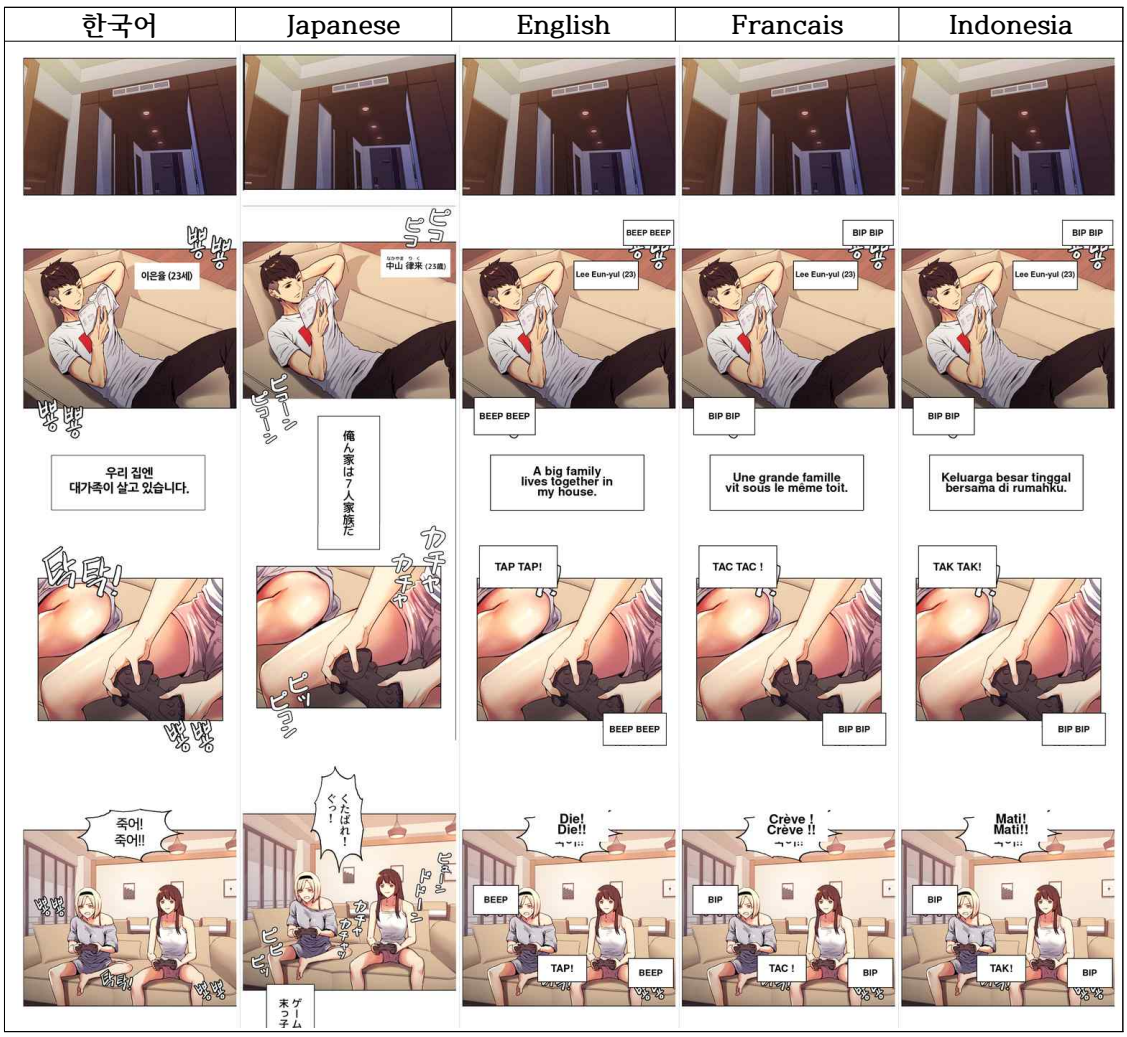
2.1 연구내용

본 연구는 AI 기반 웹툰 현지화의 문화 적합성을 정량적으로 평가하는 문화 적합도 지표(Cultural Responsiveness Score, CRS)를 구축한다. 국가문화 조건은 CEQ를 통해 설정하되, 국가문화 값만으로 개별 번역의 품질을 판정하지 않고 실제 번역문과 패널에서 관찰되는 근거를 중심으로 평가한다. 긍정 적합성은 ① 의성어·효과음의 현지화 적절성, ② 문화특정항목(CSI)의 전환·전달 적절성, ③ 인물 관계·말투의 화용적 적절성, ④ 유머·언어유희·밈의 기능적 재현성, ⑤ 이미지-텍스트의 의미·정서적 정합성의 다섯 차원으로 구성한다. 문화적 금기·혐오 등의 문화적 위험과 번역문 누락·중복·잘림·원문 잔존·배치 및 가독성 오류 등의 식자 위험은 감점 요소로 반영한다.

최종 CRS는 다섯 긍정 차원의 가중합에서 두 위험 감점값을 차감하여 0-100점으로 산출한다. 다만 심각한 문화적 위험이 확인되면 총점과 관계없이 자동 연재를 제한하는 하드 게이트를 적용한다. 원어민 인간 평가는 자동점수에 합산하지 않고, CRS의 수렴 타당도와 신뢰도를 검증하며 가중치·감점 규칙·게이팅 임계값을 보정하는 인간 정렬(human alignment) 절차로 활용한다.

2.2 연구대상 및 방법

CRS의 전체 타깃 언어는 일본어·프랑스어·인도네시아어·영어이며, 예비 적용 사례는 동일한 한국 웹툰 장면의 한국어 원문과 일본어·영어 현지화본으로 구성한다. 인물 관계를 설명하는 대사와 초인종·휴대전화 진동 등의 효과음이 언어권별로 번역·식자되는 방식을 비교한다.



[그림 2] 한국어 원문과 일본어·영어 현지화본의 CRS 평가 사례

CRS는 원문·번역문 텍스트, 원문·현지화 패널의 이미지 쌍, 타깃 독자 프로필을 입력으로 하며, 타깃 국가의 CEQ 조건을 함께 적용하여 말풍선·패널·에피소드 단위의 결과를 단계적으로 집계한다. LLM-as-a-Judge는 의성어·효과음, 문화특정항목(CSI), 인물 관계와 말투, 유머·밈을 0-100점으로 직접 평가한다. 비전-언어 모델은 인물의 표정·행동·장면 을 맥락과 번역문 간 이미지-텍스트 정합성을 동일한 척도로 평가한다(Li et al., 2022).

평가 대상 현상이 없으면 N/A로 분류하여 산출에서 제외하고, 입력이나 근거가 부족하면 NOT_EVALUABLE로 처리한다. N/A를 제외한 차원의 가중치는 합이 1이 되도록 재정규화한다. 문화적 위험과 식자·배치·가독성 위험은 별도로 감점하되, 동일한 오류를 긍정 점수와 감점에 중복 반영하지 않는다. 문화적 위험은 원문의 의도, 작품의 장르·연령등급, 현지 법규 및 플랫폼 정책을 고려하여 판단한다. 자동 CRS는 타깃 문화권의 전문 번역가와 일반 독자의 자연스러움·수용성 평가와 비교하여 타당도와 신뢰도를 검증한다.

III. 지표 구축 결과 및 검증 계획

3.1 구축 결과

CRS는 다섯 긍정 차원의 가중합에서 문화적 위험과 식자·배치·가독성 위험을 감점하고, 인간 정렬 절차로 자동 평가를 검증하는 진단형 모형이다. 이 과정에서 CEQ는 국가 간 문화 차이를 개별 번역의 직접 점수로 사용하지 않고, 국가별 평가조건과 제한적 상대 가중치를 설정하는 역할을 한다. 이를 통해 최종 점수와 함께 품질 저하가 발생한 차원과 원인을 구체적으로 제시할 수 있다.

3.2 검증 계획



[그림 3] CRS의 타당도·신뢰도 검증 및 평가체계 보정 절차

자동 CRS는 원어민의 문화적 자연스러움 평정 및 BLEU·COMET과 비교하여 수렴·변별 타당도를 검증한다. 반복 채점의 급내상관계수와 평가자 간 Krippendorff's α(Krippendorff, 2018)로 신뢰도를 측정하고, 감점 요소 제거 모형과의 비교로 위험 탐지 성능을 확인한다. CEQ 적용에 따른 평가조건 및 가중치 조정의 효과 역시 원어민·전문가 평가와 비교하여 점검한다. 현재 수치는 예시값이며 실제 다국어 웹툰을 활용한 파일럿 평가를 통해 확정한다.

IV. 함의

CRS는 문화 할인을 현지화 과정에서 조절되는 수용의 문제로 재구성하고, 번역 정확성과 구분되는 문화 적합성을 정량화한다. CEQ를 통해 국가 간 문화 차이를 평가 조건에 반영하면서도 국가문화 값을 개별 번역의 품질점수로 직접 사용하지 않는다는 점에서 문화적 맥락과 실제 번역 근거를 구분한다. 문화·화용·멀티모달 요인과 위험 감점을 결합해 자연스러움과 안전성을 평가하고, 점수와 위험 수준에 따라 자동 통과·전문가 검수·재현지화로 연결하는 품질 게이팅에 활용할 수 있다. 이는 전문가 자원을 고위험·고불확실성 사례에 집중시키는 방식이다. 향후 다국어 웹툰과 원어민 평가를 통해 가중치·임계값 및 모델 편향을 검증하고, 애니메이션·게임·광고 등으로 적용 범위를 확장할 수 있다.

참고문헌

[1] Hoskins, C., & Mirus, R. (1988). Reasons for the US dominance of the international trade in television programmes. *Media, Culture & Society, 10*(4), 499-515. https://doi.org/10.1177/016344388010004006

[2] Hofstede, G. (2011). Dimensionalizing cultures: The Hofstede model in context. *Online Readings in Psychology and Culture, 2*(1), Article 8. https://doi.org/10.9707/2307-0919.1014

[3] Banerjee, S., & Lavie, A. (2005). METEOR: An automatic metric for MT evaluation with improved correlation with human judgments. In *Proceedings of the ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation and/or Summarization* (pp. 65-72). Association for Computational Linguistics. https://aclanthology.org/W05-0909/

[4] Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: A method for automatic evaluation of machine translation. In *Proceedings of the*

40th Annual Meeting of the Association for Computational Linguistics (pp. 311-318). Association for Computational Linguistics. https://doi.org/10.3115/1073083.1073135

[5] Rei, R., Stewart, C., Farinha, A. C., & Lavie, A. (2020). COMET: A neural framework for MT evaluation. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing* (pp. 2685-2702). Association for Computational Linguistics. https://doi.org/10.18653/v1/2020.emnlp-main.213

[6] Li, J., Li, D., Xiong, C., & Hoi, S. C. H. (2022). BLIP: Bootstrapping language-image pre-training for unified vision-language understanding and generation. In *Proceedings of the 39th International Conference on Machine Learning* (pp. 12888-12900). PMLR.

[7] Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., & Stoica, I. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. *Advances in Neural Information Processing Systems, 36*, 46595-46623.

[8] Krippendorff, K. (2018). *Content analysis: An introduction to its* methodology (4th ed.). SAGE Publications.

[9] Kogut, B., & Singh, H. (1988). The effect of national culture on the choice of entry mode. *Journal of International Business Studies, 19*(3), 411-432.

[10] Reinecke, K., & Bernstein, A. (2013). Knowing what a user likes: A design science approach to interfaces that automatically adapt to culture. *MIS Quarterly, 37*(2), 427-453.

주제어: 문화 적합도, 웹툰 현지화, 문화 할인, 멀티모달 AI, LLM-as-a-Judge, Human-in-the-loop